



Detecção e

Reconstrução de Malha Viária

Reconhecimento de padrões em imagens de satélite

atributos


classificação

estrutura

Beatriz Vocurca Frade

Johnatan Augusto Moreira do Carmo


Marina Alves Resende



Objetivo do Trabalho

A partir de uma imagem de satélite, reconhecer padrões visuais associados a vias.

- ▶ identificar regiões de via;
- ▶ distinguir asfalto e terra;
- ▶ sobrepor a detecção;
- ▶ reconstruir conectividade;
- ▶ exportar grafo da malha.




Formulação em Reconhecimento de Padrões

Cada pixel ou pequena vizinhança é tratado como uma amostra.

$$x \rightarrow \phi(x) = [c_{rgb}, c_{hsv}, l_{lab}, \sigma_{local}, s_{linear}]$$
$$\omega \in \{fundo, asfalto, terra\}$$

- ▶ x : padrão observado na imagem;
- ▶ $\phi(x)$: vetor de características;
- ▶ ω : classe estimada pelo sistema.



A abordagem implementada é explicável: usa regras determinísticas em vez de treinamento supervisionado, porque a entrega não possui máscaras anotadas.

Desafios de Generalização

variabilidade

Cidades, sensores, escala, iluminação e resolução mudam a aparência da mesma classe.

ambiguidade

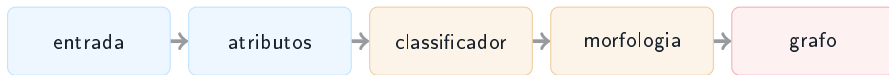
Telhados, solo exposto, estacionamentos e sombras podem gerar padrões parecidos com vias.

topologia

Pequenas falhas na máscara quebram arestas; ruídos conectados criam cruzamentos falsos.



Pipeline do Sistema




- ▶ entrada: imagens em data/raw;
- ▶ pré-processamento: bilateral + CLAHE;
- ▶ descritores: cor, textura e linearidade.
- ▶ decisão: fundo, asfalto ou terra;
- ▶ refinamento: componentes e forma;
- ▶ saída: imagens, JSON e GraphML.

Extração de Características

O padrão “via” é descrito por evidências complementares.

Atributo	Papel
RGB	relação entre canais
HSV	matiz, saturação, sombra
Lab	luminância realçada
textura	homogeneidade local
linearidade	formato alongado



Classificador por Regras


A decisão combina conhecimento de domínio e limiares adaptados à imagem.

$$M = A \cup (T \cap L)$$

$$A = sat_{baixa} \cap cinza \cap homog \cap visivel$$

$$T = matiz_{quente} \cap solo_{rgb} \cap homog \cap visivel$$


- ▶ A : hipótese de asfalto;
- ▶ T : hipótese de terra;
- ▶ L : suporte linear exigido para terra.




Suporte Linear e Invariância

Vias são padrões alongados, não apenas regiões de uma cor específica.

- ▶ Canny detecta bordas locais;
- ▶ kernels lineares cobrem 0° a 150° ;
- ▶ Hessiana multi-escala destaca cristas;
- ▶ solo de terra só entra se houver $L > 0,15$.




Segmentação e Morfologia



A classificação pixel a pixel precisa de coerência espacial.

- ▶ fechamento conecta pequenas quebras;
- ▶ abertura remove ruído isolado;
- ▶ componentes pequenos são descartados;
- ▶ regiões compactas demais são penalizadas;
- ▶ a sobreposição permite inspeção visual.

Reconhecimento Estrutural




Depois da segmentação, o padrão deixa de ser só pixel e vira estrutura.

$$grau(p) = \sum_{q \in N_8(p)} S(q)$$

- ▶ S : esqueleto binário;
- ▶ grau 1: extremidade;
- ▶ grau 2: ponto intermediário;
- ▶ grau ≥ 3 : interseção;
- ▶ agrupamento por componentes define os nós.

Grafo da Malha Viária



$$G = (V, E)$$

- ▶ V : extremidades e interseções;
- ▶ E : caminhos do esqueleto entre vértices;
- ▶ peso: comprimento em pixels;
- ▶ geometria: coordenadas (x, y) ;
- ▶ saída: maior componente conectado.

JSON + GraphML

Resultados da Execução

Métrica	Valor
Pixels classificados como via	44.037
Razão de pixels de via	7,47%
Componentes na máscara	31
Nós no grafo final	18
Arestas no grafo final	19
Pixels de asfalto	24.469
Pixels de terra	19.568

O que essas métricas dizem.

- ▶ métricas não substituem máscara anotada;
- ▶ ajudam a validar volume da segmentação;
- ▶ permitem verificar complexidade topológica;
- ▶ revelam fragmentação e falsos positivos.

Avaliação Crítica

Pontos fortes.

- ▶ pipeline completo e executável;
- ▶ decisões interpretáveis;
- ▶ saídas visuais e topológicas;
- ▶ não depende de treinamento.

Limitações.

- ▶ avaliação sem ground truth;
- ▶ sensível a iluminação e sensor;
- ▶ falsos positivos visualmente parecidos;
- ▶ grafo depende da continuidade da máscara.

Reconhecer padrões e reconstruir estrutura

avaliar

IoU, precisão, revocação,
F1 e comparação com
OpenStreetMap.

aprender

U-Net, DeepLab ou
SegFormer com base
anotada.

refinar

Fechamento topológico e
remoção supervisionada de
ruído.

$$\text{Imagem} \rightarrow M \rightarrow S \rightarrow G = (V, E)$$